

Etapa 1: Conociendo el problema

Miranda Cornejo Ahuja

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01571668@tec.mx
Equipo 2

Natalia Cervantes González

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a00838465@tec.mx
Equipo 2

Ian Roberto Rendón Berlanga

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01384161@tec.mx
Equipo 2

Hugo Jaime Valdés

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01384039@tec.mx
Equipo 2

I. INTRODUCCIÓN

Para explicar el reto correspondiente a esta materia, llegó a clase la Doctora Erika Castaño-Moreno, que es investigadora postdoctoral en el Institute for Obesity Research del Tecnológico de Monterrey en el campus Monterrey. La Dra. cuenta con expertise en metabolismo del carbono uno, vitaminas, programación fetal, obesidad materna y la doble carga de malnutrición. Anteriormente estuvo asociada al INTA de Chile, además ha publicado investigaciones sobre nutrición y salud metabólica, con las que acumula más de 280 citas en Google Scholar, y actualmente contribuye a unidades interdisciplinarias enfocadas en obesidad como problema de salud pública en México.

De esta manera, la experta nos compartió que la ingesta de ácido fólico es crucial para prevenir defectos del tubo neuronal en recién nacidos, así como para evitar otros problemas de salud. Es por esto que, en Chile, se implementó la fortificación de harina de trigo con ácido fólico como medida preventiva desde el año 2000; sin embargo, su efectividad e impacto no han sido propiamente evaluados aunque representen una necesidad urgente para la mejora de las políticas de salud pública.

Cuando se analizan problemas relacionados con la nutrición materna y la salud infantil es necesario considerar varios aspectos que influyen tanto en la calidad del análisis como en la interpretación de los resultados. Entre ellos destacan la calidad y la estructura de los datos disponibles, la heterogeneidad de la población estudiada y la relación entre los factores de exposición nutricional y los resultados de salud. Además, este tipo de estudios suele involucrar conjuntos de datos con múltiples variables, lo que introduce retos asociados a la dimensionalidad de la información y a la identificación de patrones relevantes dentro de los datos.

A esto se suman consideraciones éticas y de salud pública, ya que los resultados de este tipo de análisis pueden influir directamente en la formulación de políticas orientadas a mejorar la salud materno-infantil.

En este contexto, las variables que aparecen en el análisis suelen pertenecer a diferentes categorías. Por un lado, se encuentran las variables nutricionales, relacionadas con la ingesta de nutrientes a través de alimentos o suplementos. También aparecen variables maternas y demográficas, como edad, nivel educativo o condiciones socioeconómicas, que pueden influir en los hábitos alimenticios y en el acceso a servicios de salud. Asimismo, existen variables clínicas asociadas al embarazo, como el número de controles prenatales o la presencia de complicaciones durante la gestación, y variables neonatales que describen los resultados en el recién nacido, como peso al nacer o edad gestacional. La interacción entre estas variables permite analizar de manera más completa los factores que influyen en la salud de la madre y del recién nacido.

A nivel internacional existen diversos estándares que regulan la ingesta de ácido fólico y las estrategias de fortificación de alimentos. La Organización Mundial de la Salud recomienda que las mujeres en edad reproductiva consuman aproximadamente 400 microgramos diarios de ácido fólico con el objetivo de prevenir complicaciones durante el embarazo, especialmente los defectos del tubo neural en los recién nacidos. En este contexto, algunos países han implementado políticas públicas de fortificación de alimentos básicos, como la harina de trigo, con ácido fólico. Estas medidas buscan aumentar el consumo de este micronutriente en la población y contribuir a mejorar los indicadores de salud materna e infantil mediante una estrategia preventiva de amplio alcance.

II. DESARROLLO

El estudio de estructuras de correlación en datos que tienen una alta dimensión necesita el uso de herramientas matemáticas que ayuden a capturar relaciones y patrones en los datos que pueden no ser vistos o bien visualizados utilizando métodos estadísticos tradicionales. El Análisis Topológico de datos o TDA, es un enfoque que modela conjuntos de datos como espacios geométricos que pueden ser analizados con herramientas de topología algebraica.

Gunnar Carlsson, introduce esta perspectiva de la topología en su artículo *Topology and Data*, donde menciona que la homología persistente ayuda a detectar características estructurales robustas, tales como componentes conexas y ciclos, el cuál lleva a reflejar ciertas correlaciones en datos complejos. Este enfoque tiene relevancia al tener variables que no son fácilmente representables mediante el uso de matrices de correlación convencional. Una herramienta concreta muy utilizada dentro del TDA es el algoritmo Mapper, mencionado en el artículo *Topological Methods for the Analysis of High Dimensional Data Sets and 3D Object Recognition*. Este algoritmo permite construir representaciones gráficas que capturan la estructura conectiva de los datos. Es un método muy eficaz al momento de realizar la identificación de subgrupos y patrones de transcripción al tener espacios de alta dimensión, en este caso, es de interés proporcionar una representación de los datos conservando relaciones entre las observaciones que estén altamente correlacionadas.

Existe una aplicabilidad empírica de las técnicas mencionadas en distintos contextos, por ejemplo, en un contexto biomédico, donde de acuerdo a el artículo *Extracting Insights from the Shape of Complex Data Using Topology*, se muestra cómo el uso del análisis topológico permitió extraer subestructuras significativas a través de datos biológicos complejos. Dicho análisis reveló la existencia de agrupamientos que no emergen mediante métodos lineales. De forma similar en el contexto de *Topology based data analysis identifies a subgroup of breast cancers* se identificó un subtipo relevante mediante el uso del algoritmo de Mapper, poniendo en evidencia que la estructura topológica global de los datos puede contener información estructural relevante sobre resultados en salud. Este estudio resalta que las técnicas topológicas capturan configuraciones globales reflejando dependencias estructurales entre múltiples variables simultáneamente, no solamente correlaciones locales.

Investigando el caso de la fortificación con ácido fólico en Chile, existen estudios como *Folic Acid Fortification of Wheat Flour: Chile* así como el estudio de *Impact of Folic Acid Fortification in Chile*, en los cuáles documentan los impactos en la población que son relevantes en indicadores de salud perinatal. Estos estudios fueron realizados principalmente con el uso de análisis estadístico tradicional, sin embargo, si se toma que la ingesta de ácido fólico está relacionada

con variables socioeconómicas, patrones de suplementación o condiciones gestacionales, entre otras variables, se puede llegar a la suposición de que la estructura de correlación subyacente podría llegar a presentar configuraciones no lineales que requieren de herramientas de análisis más robustos.

La literatura revisada demuestra que el TDA ha sido exitosamente utilizado para el estudio de estructuras de dependencia complejas en distintos contextos. Dado a que nuestra problemática planteada involucra múltiples variables interrelacionadas, el uso de técnicas topológicas es respaldada por evidencia empírica sólida.

Tomando en cuenta la problemática dada, así como los recursos a nuestra disposición, se busca desarrollar un análisis topológico exhaustivo y un informe sobre la ingesta de ácido fólico en mujeres chilenas, así como de su impacto en la salud infantil; esto a través de técnicas de análisis topológico de datos con el objetivo de segmentar la población estudiada y dar información relevante sobre esta población.

III. DESCRIPCIÓN INDIVIDUAL PROBLEMA ESPECÍFICO

- **Natalia:** Personalmente, son años los que he pasado descubriendo el mundo de la nutrición y la manera en la que, algo tan simple como la dieta, afecta a gran escala en la vida humana. Este reto me parece muy interesante por el simple hecho de que combina las implicaciones del consumo de un producto en la dieta de mujeres embarazadas, y su estudio topológico. En este reto quisiera aprender, además de aplicaciones topológicas en el área de salud, métodos para mover y acomodar los datos topológicamente para obtener conclusiones relevantes para la Socio Formadora, además de los efectos en masa de la introducción de un producto modificado, como la harina de trigo, en el curso de los embarazos de las mujeres chilenas.
- **Miranda:** Después de realizar la investigación pertinente al análisis topológico y las diversas aplicaciones en donde ha sido aplicado exitosamente, me llama la atención el saber como podría verse alguna ramificación de subgrupos hechos con algoritmos de topología, como Mapper, para poder identificar si analizando la salud de los bebés y con su crecimiento continuo se podría llegar a identificar con precisión la cantidad de ingesta de ácido fólico de las mujeres chilenas, al igual que identificar si se tiene alguna relación con las variables socioeconómicas y salud de ellas.
- **Hugo:** Una forma nueva de hacer análisis estadístico/matemático de un conjunto de datos. He escuchado demasiado sobre que en ciencia de datos se descubren patrones que no se obtienen con métodos convencionales, sin embargo no entiendo realmente a que se refiere eso o no lo he percibido. Me gustaría a través del reto como el análisis topológico puede abrir

las puertas a un análisis diferente al que he visto hasta ahora.

- **Ian:** Entender cómo se utiliza la topología como herramienta aplicada a un contexto real. Conocer y explorar técnicas del TDA para poder brindar valor a una comunidad, el poder rescatar y concluir aseveraciones que estén respaldadas por evidencia tangible. También el entender las diferencias principales entre las técnicas estadísticas usuales y las técnicas empleadas en este curso, comprender lo que conceptos como la homología y la persistencia pueden ayudar a describir los patrones que no son visibles dentro del conjunto de datos, entender por qué no se pueden percibir.

IV. OBJETIVO Y JUSTIFICACIÓN

Dados los objetivos individuales descritos anteriormente por los integrantes del equipo, podemos encontrar similitudes en los aprendizajes que cada uno desea obtener en este reto, como la profundización de las técnicas topológicas para el mejor entendimiento de los datos, además de las implicaciones de los resultados de este análisis en la salud de las personas involucradas. De esta manera, se pudiera resumir el objetivo conjunto del equipo cómo desarrollar un análisis topológico que nos permita aprender con claridad sus posibles usos y aplicarlo para obtener conclusiones relevantes sobre la población estudiada.

V. DESCRIPCIÓN DE FUENTES DE INFORMACIÓN

Los datos que se proporcionarán para el desarrollo de este proyecto fueron recopilados por el *Institute for Obesity Research*. Estos fueron obtenidos a partir de la recolección de resultados de encuestas a mujeres chilenas sobre la ingesta de ácido fólico. En estos también se incluye información clave acerca de la salud, como pueden ser el peso al nacer y la prematuridad. Estos datos precisan de un uso de técnicas avanzadas debido a su complejidad.

La base de datos consta de cuatro conjuntos distintos. El primero es la ingesta de ácido fólico en el embarazo planteado como final. Este se compone de un total de 1170 observaciones, respuestas de mujeres a la encuesta, con alrededor de 61 variables. Se pueden destacar cuatro tipos de variables de esta encuesta. Las relacionadas a los datos maternos, como la edad, número de hijos, región y nivel educacional; otra categoría puede ser los datos del último embarazo, como la fecha de nacimiento del hijo, sexo de este mismo, peso al nacer y la edad gestal; podría considerarse como otra categoría las condiciones durante el embarazo, aquí se contempla preeclampsia y si hay enfermedades o situaciones de riesgo; finalmente la última categoría son las relativas al consumo de ácido fólico, suplementación, periodo de consumo y la información nutrimental.

La siguiente base de datos son los resultados de la encuesta online y su procesamiento. La base original presenta 847

observaciones y 33 variables. Algunas de las preguntas planteadas en este cuestionario son directas, como edad, nacionalidad, región de residencia, etc. La base de consenso en este segundo conjunto de datos tiene 854 observaciones, con 78 columnas. Esta parece ser una base de datos depurada y codificada, en la que se incluyen variables como edad de la madre, una codificación de la nacionalidad, así como codificación de región y nivel educacional, y el número de embarazo. En otra tabla se presentan los códigos para convertir variables a categóricas.

La tercera base parece ser una ya filtrada y seleccionada para su análisis en su hoja principal. En esta se pueden encontrar 705 observaciones y 66 variables. Las variables principales que pueden resultar relevantes para la investigación son la edad de la madre, nacionalidad, región, educación, fecha de nacimiento del hijo, número de embarazo y el periodo de consumo de ácido fólico. Se anexa una página destinada a los códigos de las variables categóricas.

Este proyecto contempla su impacto de manera directa en el área de salud de manera significativa, esto en uno de los aspectos más relevantes determinantes prevenibles de salud materno-infantil, la ingesta del ácido fólico adecuada durante el periodo periconcepcional y el embarazo. Desde la implementación de la fortificación obligatoria de harina con ácido fólico en Chile en el año 2000, en este país se han logrado importantes avances en la reducción de defectos del tubo neural. No obstante, existen brechas relativas a desigualdades socioeconómicas, acceso a suplementación, calidad de dieta y condiciones metabólicas de las madres.

El que se use TDA en este contexto representa una innovación metodológica con un impacto social que sea tangible por varias razones. En primer lugar, la diferencia entre el uso de técnicas estadísticas contra técnicas topológicas es que TDA permite detectar estructuras complejas en datos multivariados. Esto facilita la ideación y focalización de políticas públicas, evitando estrategias que puedan no considerar heterogeneidad en la población. Segundo, la optimización de políticas de salud pública. El proyecto puede contribuir a mejorar programas en el sistema de salud chileno relativos al control prenatal, nutrición materna y prevención de malformaciones congénitas. En tercer lugar, al revelar patrones estructurales en los niveles socioeconómicos, región geográfica, acceso a los servicios de salud, nivel educativo, el proyecto puede aportar evidencia para reducir desigualdades en resultados perinatales, de acuerdo a los objetivos de desarrollo sustentable sobre salud y bienestar.

VI. IMPACTO SOCIAL

El impacto social de este proyecto radica en la capacidad de este para poder transformar datos en primera instancia complejos, en evidencia que resulte útil para la toma de decisiones sobre la salud pública. Identificando los patrones ocultos en la ingesta de ácido fólico y su relación con

resultados perinatales, el estudio contribuye a aspectos como la optimización de intervenciones preventivas, reducción de desigualdades y mejorar la salud materno-infantil.

VII. ANEXOS:

Github

REFERENCES

- [1] Carlsson, G. (2009). TOPOLOGY AND DATA. BULLETIN (New Series) of the AMERICAN MATHEMATICAL SOCIETY, 46(2). <https://www.ams.org/journals/bull/2009-46-02/S0273-0979-09-01249-X/S0273-0979-09-01249-X.pdf>
- [2] Singh, G., Mémoli, F., & Carlsson, G. (2007). Topological Methods for the Analysis of High Dimensional Data Sets and 3D Object Recognition. In Eurographics Symposium on Point-Based Graphics. <https://research.math.osu.edu/tgda/mapperPBG.pdf>
- [3] Lum, P. Y., Singh, G., Lehman, A., Ishkanov, T., Vejdemo-Johansson, M., Alagappan, M., Carlsson, J., & Carlsson, G. (2013). Extracting insights from the shape of complex data using topology. Scientific Reports, 3(1). <https://doi.org/10.1038/srep01236>
- [4] Nicolau, M., Levine, A. J., & Carlsson, G. (2011). Topology based data analysis identifies a subgroup of breast cancers with a unique mutational profile and excellent survival. Proceedings of the National Academy of Sciences, 108(17), 7265–7270. <https://doi.org/10.1073/pnas.1102826108>
- [5] Crider, K. S., Bailey, L. B., & Berry, R. J. (2011). Folic Acid Food Fortification—Its History, Effect, Concerns, and Future Directions. Nutrients, 3(3), 370–384. <https://doi.org/10.3390/nu3030370>
- [6] Castillo-Lancellotti, C., Tur, J. A., & Uauy, R. (2012). Impact of folic acid fortification of flour on neural tube defects: a systematic review. Public Health Nutrition, 16(5), 901–911. <https://doi.org/10.1017/s1368980012003576>