

Etapa 2: Comprensión y Preparación de los Datos

Miranda Cornejo Ahuja

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01571668@tec.mx
Equipo 2

Natalia Cervantes González

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a00838465@tec.mx
Equipo 2

Ian Roberto Rendón Berlanga

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01384161@tec.mx
Equipo 2

Hugo Jaime Valdés

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01384039@tec.mx
Equipo 2

I. INTRODUCCIÓN

Para explicar el reto correspondiente a esta materia, llegó a clase la Doctora Erika Castaño-Moreno, que es investigadora postdoctoral en el Institute for Obesity Research del Tecnológico de Monterrey en el campus Monterrey. La Dra. cuenta con expertise en metabolismo del carbono uno, vitaminas, programación fetal, obesidad materna y la doble carga de malnutrición. Anteriormente estuvo asociada al INTA de Chile, además ha publicado investigaciones sobre nutrición y salud metabólica, con las que acumula más de 280 citas en Google Scholar, y actualmente contribuye a unidades interdisciplinarias enfocadas en obesidad como problema de salud pública en México.

De esta manera, la experta nos compartió que la ingesta de ácido fólico es crucial para prevenir defectos del tubo neuronal en recién nacidos, así como para evitar otros problemas de salud. Es por esto que, en Chile, se implementó la fortificación de harina de trigo con ácido fólico como medida preventiva desde el año 2000; sin embargo, su efectividad e impacto no han sido propiamente evaluados aunque representen una necesidad urgente para la mejora de las políticas de salud pública.

A. Objetivo y técnicas estadísticas

Después de llevar a cabo una profunda revisión de los datos proporcionados para este reto, se determinó que el objetivo con el que se quería trabajar es el de **determinar si el origen de la ingesta de ácido fólico (suplementación o consumo de carbohidratos fortificados), se asocia con las diferencias de las condiciones del recién nacido al momento del parto**. Este objetivo nos dará cuál tipo de consumo de AF tiene la asociación más fuerte a las características del bebé al nacer. Y para llegar a las conclusiones esperadas se tiene considerado hacer un análisis estadístico que modele

directamente el cambio en dichas características de nacimiento en función de las ingestas de AF con regresiones lineales múltiples y binarias. Por supuesto que el análisis comenzaría con la exploración descriptiva y bivariada de los datos para poder ir escalando a modelos simples y múltiples donde se encuentren las relaciones entre las variables de ingesta de AF y las que definen al bebé al nacer (como peso al nacer, edad gestacional y presencia de patologías).

II. DESCRIPCIÓN DE VARIABLES

Se proporcionaron 3 bases de datos para usar en este reto, las cuales recopilan información de diferentes encuestas hechas a mujeres embarazadas de la región estudiada con el fin de estudiar su ingesta de Ácido Fólico, además de otras características de su estilo de vida. Es en el análisis de estas bases de datos donde se encuentra el primer punto importante de este reporte: las 3 bases de datos cuentan con preguntas cuya respuesta requerida es la misma, solo que formuladas de diferente manera; es por eso que, al elegir nuestras variables de interés, se tuvieron que elegir por cada base de datos, cuidando que contuvieran nuestra información de interés:

Las variables se dividieron en 3 categorías dependiendo del objeto que describen: en relación a la madre, al recién nacido y a la ingesta de AF, tratando de cubrir los mismos tipos de datos en las 3 diferentes encuestas.

1) Base de datos ingesta de AF en embarazo

a) En relación a la madre

- **edad:** Edad de la madre al momento de dar a luz.
- **region_chile:** Región del país de Chile del parto de la madre.
- **sitgest:** Condición que la madre presentaba al momento de la gestación (enfermedad)

b) En relación al recién nacido

- **pnacer:** Peso del recién nacido al momento de nacer.
 - **Sexo:** Sexo del recién nacido.
 - **probnac:** Si el recién nacido heredó la condición que la madre tuviera al momento del embarazo.
- c) En relación a la ingesta de AF
- **¿Consumió suplementos de Ácido Fólico o Vitaminas durante su embarazo?:**
 - **Antes del embarazo**
 - **1-3 meses**
 - **4-6 meses**
 - **7-9 meses**
 - **Durante todo el embarazo**
 - **Durante el periodo de lactancia**
 - **No consumi suplemento en ningún periodo**
Después se hace la pregunta de si se consumió pan durante el embarazo, y se tienen las siguientes variables binarias
 - **Marraqueta**
 - **Hallulla**
 - **Pan molde blanco**
 - **Pan molde**
- 2) Base de datos AF 2 más completa
- a) En relación a la madre
- **Edad Madre:** Edad de la madre al momento de dar a luz.
 - **Región C:** Región del país de Chile del parto de la madre.
 - **Nivel Educativo C:** Mayor nivel de educación alcanzado al momento del parto por la madre.
 - **IMC Pregestacional:** Índice de Masa Corporal de la madre previo a la gestación.
 - **Condición Materna C:** Condición que la madre presentaba al momento de la gestación (enfermedad).
- b) En relación al recién nacido
- **Sexo RN C:** Sexo del recién nacido.
 - **Peso RN:** Peso del recién nacido al momento de nacer.
 - **EG RN:** Semana del embarazo en la que sucedió el parto.
 - **Problema Salud RN C:** Si el recién nacido heredó la condición que la madre tenía al momento del embarazo.
- c) En relación a la ingesta de AF
- **Consumo SAF:** Si la madre consumió Suplemento de Ácido Fólico durante el embarazo.
 - **SAF mg AF/día:** Miligramos de Suplemento de Ácido Fólico consumidos al día por la madre.
 - **Pan mg AF día:** Miligramos de Ácido Fólico consumido en pan al día por la madre.
 - **Pasta ug AF día:** Miligramos de Ácido Fólico consumido en pasta al día por la madre.
 - **Total AF Aporte**

PASTA+PAN+SAF+OSAF+MAF: Total de aporte en miligramos de Ácido Fólico consumido en pasta, pan, suplementos, etc.

- 3) Base de datos encuesta AF2 más completa para comparar
- a) En relación a la madre
- **Región:** Región del país de Chile del parto de la madre.
 - **Educación:** Mayor nivel de educación alcanzado al momento del parto por la madre.
 - **Condición mamá:** Condición que la madre presentaba al momento de la gestación (enfermedad).
- b) En relación al recién nacido
- **Sexo hijo:** Sexo del recién nacido.
 - **EG hijo (sem):** Semana del embarazo en la que sucedió el parto.
 - **Patología RN:** Si el recién nacido presentó una enfermedad.
- c) En relación a la ingesta de AF
- **¿Consume SAF?:** Si la madre consume algún Suplemento de Ácido Fólico.
 - **mgAF/día SAF:** Miligramos de Suplemento de Ácido Fólico consumidos al día por la madre.
 - **mgAF/día Suplementos y multivitamínico 1°T:** Miligramos de Suplemento de Ácido Fólico y Multivitamínico 1°T consumidos al día por la madre.
 - **Total mg/d AF suple y pan:** Total de miligramos de Ácido Fólico consumido por la madre en suplementos y pan.
 - **¿Consumió pan?:** Si la madre consumió pan.
 - **mgAF/unidad pan:** Miligramos de Ácido Fólico por unidad de pan consumida por la madre.

III. COMPRENSIÓN DE LOS DATOS

A. Dimensión del dataset

- 1) Base de datos ingesta de AF en embarazo
 - Dimensión: (1170,63)
- 2) Base de datos AF 2-más completa
 - Dimensión: (845,78)
- 3) Base de datos encuesta AF2 más completa para comparar
 - Dimensión: (705,66)

B. Descripción de las variables

Con la función de info() en cada una de las bases de datos, se pudo obtener información de cada variable en las bases de datos, incluyendo sus nombres, la cantidad de registros en cada una y los posibles valores que pueden tomar. En este caso, no se escogieron variables categóricas, al igual que no habían valores nulos. Las variables se observaron en est aparte para poder escoger las más completas y útiles para responder nuestro objetivo.

C. Exploración de datos:

- Medidas estadísticas:

Variables cuantitativas. Medidas de tendencia central y Medidas de dispersión.

TABLE I
BASE DE DATOS ENCUESTA AF2 MÁS COMPLETA PARA COMPARAR

Variable	Media	Mediana	Moda
Edad madre	34.376417	35.00	33.00
Educación	6.025532	6.00	6.00
Región	8.031206	7.00	7.00
Sexo hijo	1.502128	2.00	2.00
PN hijo (g)	3290.483688	3330.00	3250.00
EG hijo (sem)	38.259943	38.00	38.00
Condición mamá	2.460993	3.00	3.00
Patología RN	0.310638	0.00	0.00
¿Consume SAF?	0.774468	1.00	1.00
mgAF/día SAF	1.851165	1.00	1.00
mgAF/día Suplementos y multivitamínico 1ºT	2.184052	1.00	1.00
Total mg/d AF suple y pan	2.366371	1.26	1.26
¿Consumió pan?	0.990071	1.00	1.00
mgAF/unidad pan	0.105818	0.13	0.13

TABLE II
BASE DE DATOS INGESTA DE AF EN EMBARAZO

Variable	Media	Mediana	Moda
edad	30.081266	29.0	26.0
region_chile	9.270940	9.0	13.0
neduc	5.145299	5.0	6.0
pnacer	3345.222852	3390.0	3450.0
Sexo	1.400000	1.0	1.0
Edad_gestacion ultimo hijo	38.432990	39.0	38.0
sitgest	3.105128	0.0	0.0
probnac	0.352438	0.0	0.0
¿Consumió suplementos de Ácido Fólico o Vitaminas?	0.861538	1.0	1.0
Antes del embarazo	0.176068	0.0	0.0
1-3 meses	0.411966	0.0	0.0
4-6 meses	0.156410	0.0	0.0
7-9 meses	0.041026	0.0	0.0
Durante todo el embarazo	0.293162	0.0	0.0
Durante el periodo de lactancia	0.022222	0.0	0.0
No consumí suplemento en ningún periodo	0.129915	0.0	0.0
Marraqueta	0.664103	1.0	1.0
Hallulla	0.196581	0.0	0.0
Pan molde blanco	0.067521	0.0	0.0
Pan molde integral	0.110256	0.0	0.0
pan pita	0.048718	0.0	0.0
no como pan	0.013675	0.0	0.0

TABLE III
BASE DE DATOS ENCUESTA AF 2_MÁS COMPLETA 2

Variable	Media	Mediana	Moda
Edad Madre	34.156584	34.000000	33.00000
Region C	4.185053	1.000000	1.00000
Nivel Educativo C	4.026097	4.000000	4.00000
IMC Pre gestacional	26.968250	25.535446	19.53125
Condición Materna C	2.500593	3.000000	3.00000
Sexo RN C	1.485172	1.000000	1.00000
Peso RN	3288.963227	3323.000000	3250.00000
EG RN	38.368099	38.571429	38.00000
Problema Salud RN C	0.098458	0.000000	0.00000
Consumo SAF	0.851720	1.000000	1.00000
SAF mg AF/día	2.308709	1.000000	1.00000
Pan mg AF día	0.178517	0.160000	0.26000
Pasta µg AF día	19.141679	16.115000	32.23000
Total AF Aporte PASTA+PAN+SAF+OSAF+MAF	21.755169	17.375000	17.37500

Variables cualitativas

No tenemos variables cualitativas seleccionadas en las bases de datos con relación al objetivo.

TABLE IV
BASE DE DATOS ENCUESTA AF2 MÁS COMPLETA PARA COMPARAR

Variable	Rango	Varianza	Desviación Estándar
Edad madre	27.000	22.972456	4.792959
Educación	4.000	0.601620	0.775642
Región	15.000	7.055843	2.656284
Sexo hijo	1.000	0.250351	0.500350
PN hijo (g)	3900.000	281261.261452	530.340703
EG hijo (sem)	14.000	2.929488	1.711575
Condición mamá	2.000	0.674968	0.821564
Patología RN	9.000	1.805355	1.343635
¿Consume SAF?	1.000	0.174915	0.418229
mgAF/día SAF	5.000	3.872528	1.967874
mgAF/día Suplementos y multivitamínico 1ºT	7.500	4.036317	2.009059
Total mg/d AF suple y pan	7.735	4.020108	2.005021
¿Consumió pan?	1.000	0.009844	0.099219
mgAF/unidad pan	0.230	0.001006	0.031711

TABLE V
BASE DE DATOS INGESTA DE AF EN EMBARAZO

Variable	Rango	Varianza	Desviación Estándar
edad	212.0	73.853835	8.593825
region_chile	14.0	15.903432	3.987911
neduc	6.0	1.315055	1.146758
pnacer	5271.0	297328.891689	545.278728
Sexo	2.0	0.330881	0.575223
Edad_gestacion ultimo hijo	42.0	5.568442	2.359755
sitgest	21.0	20.727176	4.552711
probnac	13.0	2.302051	1.517251
¿Consumió suplementos de Ácido Fólico o Vitami...	1.0	0.119392	0.345531
Antes del embarazo	1.0	0.145192	0.381041
1-3 meses	1.0	0.242457	0.492399
4-6 meses	1.0	0.132059	0.363399
7-9 meses	1.0	0.039376	0.198434
Durante todo el embarazo	1.0	0.207395	0.455407
Durante el periodo de lactancia	1.0	0.021747	0.147469
No consumí suplemento en ningún periodo	1.0	0.113133	0.336353
Marraqueta	1.0	0.223261	0.472505
Hallulla	1.0	0.158072	0.397583
Pan molde blanco	1.0	0.063016	0.251030
Pan molde integral	1.0	0.098184	0.313343
pan pita	1.0	0.046384	0.215370
no como pan	1.0	0.013500	0.116188

TABLE VI
BASE DE DATOS ENCUESTA AF 2_MÁS COMPLETA 2

Variable	Rango	Varianza	Desviación Estándar
Edad Madre	28.000000	22.904194	4.785833
Region C	15.000000	17.960964	4.238038
Nivel Educativo C	4.000000	0.595518	0.771698
IMC Pre gestacional	205.815972	73.598865	8.578978
Condición Materna C	3.000000	0.630344	0.793942
Sexo RN C	1.000000	0.250077	0.500077
Peso RN	3900.000000	278351.947577	527.590701
EG RN	14.142857	2.756543	1.660284
Problema Salud RN C	1.000000	0.088869	0.298110
Consumo SAF	1.000000	0.126443	0.355588
SAF mg AF/día	15.000000	3.966464	1.991598
Pan mg AF día	0.690000	0.010390	0.101933
Pasta µg AF día	80.575000	345.881457	18.597888
Total AF Aporte PASTA+PAN+SAF+OSAF+MAF	82.248885	348.763074	18.675199

D. Exploración usando herramientas de visualización

Variables cuantitativas

Para los resultados visuales sólo se considerarán a las variables cuantitativas, puesto que carece de sentido realizar un análisis de variables que sean del tipo categóricas o binarias. Comenzando por la primera base de datos, notamos que, del primer cuartil, el 25% de las madres tienen 30 años, el 75% tiene 38 y la mediana se encuentra en los 35. Esto nos habla de una distribución relativamente centrada, sin una dispersión extrema. Esto a su vez puede ser comprobado analizando el histograma relacionado a la edad de la madre. Se puede notar que la media se encuentra entre 30 y 35 y no hay colas laterales que nos puedan indicar asimetría.

Para tener aún más refuerzo sobre la idea de la asimetría, se calcula el coeficiente de sesgo. Edad madre obtuvo un

coeficiente de asimetría de -0.15 , relativamente cerca a 0 y aproximadamente simétrica. Algo similar sucede al analizar el peso de los recién nacidos. El 25% pesa 3040 gramos, el 75% pesa 3600 y la mediana se encuentra en los 3330 gramos. Una distribución relativamente centrada. Después se obtuvo el histograma del peso de los hijos en gramos.

Finalmente para la edad gestacional de los hijos se tiene que el 25% fue de 38 semanas y el 75% de 39. No hay mucha dispersión en esa variable.

En cuanto a los valores atípicos, en la primera base de datos se tienen muchos valores atípicos en la variable de educación, precisamente 274, pero, al ser categórica, era un resultado esperable. Así mismo en la variable de región se tienen 85. Esta también es una variable categórica. En peso de recién nacido se tienen 27 outliers bajos y 7 altos. Esto nos puede hablar de casos en los que los hijos tengan un bajo peso o macrosomía. Los diagramas de caja sustentan esto.

Puede resultar útil conocer la correlación entre las distintas variables. Para ello se generó un mapa de calor, el cual se muestra en la siguiente figura. De este obtenemos resultados que nos podemos esperar de cualquier base de datos, la mayoría de las variables no presentan una correlación significativa. Las variables de la edad de gestación y del peso del recién nacido tienen una correlación de caso 0.6. Esto puede suceder porque, al estar más tiempo dentro del útero, el hijo puede desarrollarse y crecer aún más. Además, se muestra que hay variables categóricas que presentan una alta correlación. Esto puede no ser tan sustancial, puede que el responder afirmativamente para una interrogante sobre el consumo de SAF implica una respuesta en preguntas relacionadas. Tampoco se presenta una correlación significativa entre variables categóricas y las cuantitativas.




Fig. 1. Mapa de correlación de la primera base de datos

Otro aspecto a destacar de esta base de datos es que se puede tener una idea de cómo están distribuidas las madres que consumieron suplementos de ácido fólico así como la

proporción de las hijas que nacieron con alguna enfermedad. Se obtuvo el histograma de las variables categóricas del consumo de suplementos de ácido fólico. Las cantidades presentan una diferencia notable. Mientras 546 madres reportaron haber consumido los suplementos, 159 no lo hicieron. El 77.4% de las madres siguen la recomendación. Esto puede implicar que el 22.6% restante no lo hace por diversos motivos, ya sea la falta de acceso, falta de información o cuestiones socioeconómicas.




Fig. 2. Histograma de las madres que consumieron suplementos de ácido fólico

Para la segunda base de datos, se puede observar que los cuartiles presentan un comportamiento similar a los observado en la base anterior. El 25% de las madres tienen 26 años, mientras el 75% tienen 34. Con una mediana de 29 años, se puede ver que hay una dispersión centrada. En cuanto al peso del hijo recién nacido, el 25% de ellos pesa 3050 gramos, el 5% 3660. Con una mediana de 3390 gramos, también se tiene una distribución centrada. Para la edad gestacional del último hijo, prácticamente no hay dispersión, el 25% son de 38 semanas, el 75% de 40 y la mediana se posiciona en las 39. Analizando el coeficiente de sesgo de todas estas variables, la edad de gestación y el peso del recién nacido presentan asimetría negativa.

En el caso de edad de la madre, se presenta asimetría positiva. Los coeficientes de sesgo para las variables de edad de la madre, peso al nacer y edad de gestación son de 10.61, -0.76 y -8.45 , respectivamente. Las tres variables presentan algunos valores atípicos. La variable de la edad de la madre tiene 6 outliers altos, y la de edad de gestación presenta 32 outliers bajos. La variable del peso cuenta con 23 bajos y 13 altos.

En el mapa de calor para la correlación se presentan una enorme cantidad de relaciones entre variables, y una vez más, no se puede apreciar correlación entre las variables categóricas con las cuantitativas. Se muestra nuevamente una correlación notable (con coeficiente de 0.34) entre las variables de peso al nacer y edad de gestación. También se puede ver hay variables dietarias que están relacionadas entre ellas, especialmente las que contribuyen al consumo del

ácido fólico, como pueden ser suplementos, pan y pasta. Esto nos puede indicar que el consumo total no proviene de una única fuente, sino de una combinación de varias. Por cuestión de la extensión del mapa de calor, en este apartado no se incluye, pero se puede consultar en los archivos realizados para la exposición de estos resultados en las referencias. Colocando ejemplos de estas correlaciones, la variable que indica las madres que consumieron “Pan Pita” está correlacionada con la variable de las madres que consumieron pan de molde blanco con un coeficiente de 0.41. La variable para las madres que consumieron pan de molde integral está relacionada con la de “Pan Pita” con un coeficiente de 0.3). Coeficientes bajos, pero son destacables entre el resto.

Finalmente, hablando de la tercera base de datos, se puede apreciar una mayor heterogeneidad entre los datos, aspecto que hace la diferencia entre las dos bases anteriores. Esta heterogeneidad se presenta entre variables como el índice de masa corporal (IMC) y el consumo total de ácido fólico. Se detectó un valor atípico extremo en la variable del IMC. En la siguiente figura se muestra el histograma para esta variable.




Fig. 3. Histograma de IMC pregestacional

Calculando el coeficiente de sesgo para esta variable, y con un resultado de 1.19, se muestra que la forma de esta distribución es asimétrica positivamente, entonces tiene una cola extendiéndose a la derecha. El 25% de las madres que respondieron a esta encuesta tienen un IMC menor de 23.05, y el 75% un IMC menor a 29.56. Otra variable que puede resultar de interés en el análisis perteneciente a esta base de datos es el consumo total de ácido fólico, con aporte de pan, pasta, suplementos, otros suplementos, y el consumo vitamínico de ácido fólico. Se tiene que el 25% de los registros indican una cantidad menor de 5.2 miligramos, mientras el 75% consumieron menos de 33.49 miligramos. Teniendo una mediana de 17.36 miligramos, se puede decir que se sigue una distribución un tanto sesgada. Para comprobar esto, se obtuvo el histograma de la variable del consumo total. Nuevamente, otra manera de verificar la simetría de esto es calculando el coeficiente de sesgo, Este coeficiente resulta tener un valor de 0.84, indicando asimetría positiva, por lo que hay un sesgo hacia la derecha y la

distribución es asimétrica positiva.

Graficando el mapa de calor, nuevamente observamos la relación mostrada para las dos bases anteriores con respecto al peso del recién nacido y la edad gestacional, con un coeficiente de correlación de 0.58. También se destaca que el consumo total de ácido fólico está mayormente relacionado con el consumo de pasta en microgramos, con una correlación de 0.99, lo que indicaría que el total del consumo está casi por completo explicado por el consumo de pasta. Sin embargo, esto puede ser ocasionado por multicolinealidad, resultando en problemas para futuros análisis. El consumo de pan está también positivamente correlacionado, pero en menor medida que la pasta, con un coeficiente de 0.25.




Fig. 4. Mapa de calor de la tercera base de datos

IV. RESUMEN

Hasta ahora, se ha logrado delimitar con claridad la problemática de investigación y su relevancia en salud pública, así como definir el objetivo analítico del estudio: evaluar si el origen de la ingesta de ácido fólico, ya sea por suplementación o por consumo de alimentos fortificados, se asocia con diferencias en las condiciones del recién nacido al momento del parto. También se avanzó en la comprensión, selección y exploración inicial de las variables de interés, además de profundizar en la validación y limpieza de las bases de datos detectando valores faltantes, errores, duplicados e inconsistencias, con lo que se fortaleció la confiabilidad de la información disponible.

A partir de este punto, falta avanzar hacia una etapa de análisis más profunda, combinando herramientas estadísticas con técnicas de Análisis Topológico de Datos, particularmente Mapper, para identificar patrones, agrupamientos y relaciones no evidentes dentro de la población estudiada. El camino que se piensa seguir consiste en contrastar los hallazgos obtenidos con métodos estadísticos tradicionales frente a los resultados derivados del enfoque topológico, con el fin de determinar si este último permite revelar subgrupos o estructuras relevantes que no son visibles mediante enfoques convencionales.

Entre las principales preguntas que han surgido se encuentran si realmente existen diferencias identificables en los resultados neonatales según la fuente de ingesta de ácido

fólico, qué tan homogéneos o heterogéneos son los perfiles maternos dentro de la población analizada, y hasta qué punto el análisis topológico puede aportar información complementaria o más profunda que la obtenida mediante técnicas estadísticas clásicas. Estas preguntas serán la referencia para la siguiente fase del proyecto y permitirán trazar una ruta metodológica más clara para desarrollo.

V. ANEXOS:

Github

Código

Gráficos

REFERENCES

- [1] Carlsson, G. (2009). TOPOLOGY AND DATA. BULLETIN (New Series) of the AMERICAN MATHEMATICAL SOCIETY, 46(2). <https://www.ams.org/journals/bull/2009-46-02/S0273-0979-09-01249-X/S0273-0979-09-01249-X.pdf>
- [2] Singh, G., Mémoli, F., & Carlsson, G. (2007). Topological Methods for the Analysis of High Dimensional Data Sets and 3D Object Recognition. In Eurographics Symposium on Point-Based Graphics. <https://research.math.osu.edu/tgda/mapperPBG.pdf>
- [3] Lum, P. Y., Singh, G., Lehman, A., Ishkanov, T., Vejdemo-Johansson, M., Alagappan, M., Carlsson, J., & Carlsson, G. (2013). Extracting insights from the shape of complex data using topology. Scientific Reports, 3(1). <https://doi.org/10.1038/srep01236>
- [4] Nicolau, M., Levine, A. J., & Carlsson, G. (2011). Topology based data analysis identifies a subgroup of breast cancers with a unique mutational profile and excellent survival. Proceedings of the National Academy of Sciences, 108(17), 7265–7270. <https://doi.org/10.1073/pnas.1102826108>
- [5] Crider, K. S., Bailey, L. B., & Berry, R. J. (2011). Folic Acid Food Fortification—Its History, Effect, Concerns, and Future Directions. Nutrients, 3(3), 370–384. <https://doi.org/10.3390/nu3030370>
- [6] Castillo-Lancellotti, C., Tur, J. A., & Uauy, R. (2012). Impact of folic acid fortification of flour on neural tube defects: a systematic review. Public Health Nutrition, 16(5), 901–911. <https://doi.org/10.1017/s1368980012003576>